

中国传媒大学

中国传媒大学信息与通信工程学院

面向边缘端声源定位的轻量化球面卷积加速网络设计与实现

答辩人：晁萌萌　　导师：孙象然



目录

CONTENTS

01 背景及研究现状

02 研究内容总览

03 已完成工作

04 未来工作与挑战

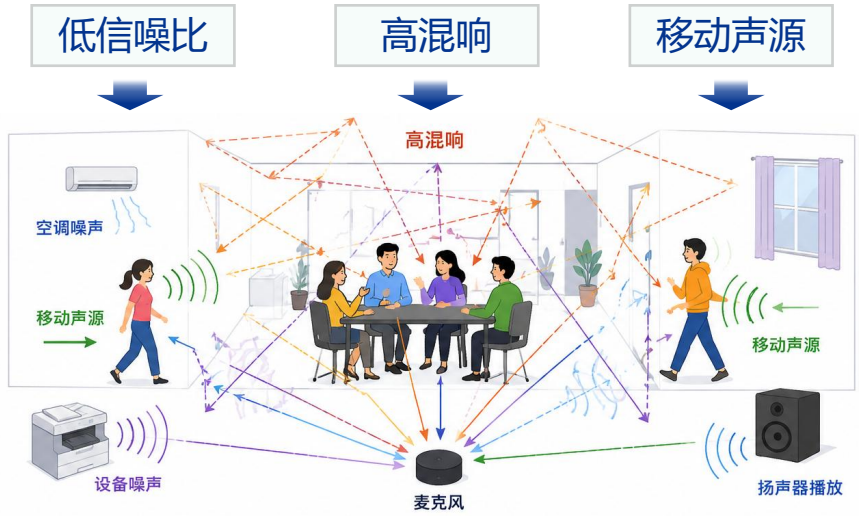
研究背景——声源方位估计的边缘部署需求

核心应用场景

智能语音交互　机器人自主导航　安防监控　智能会议终端

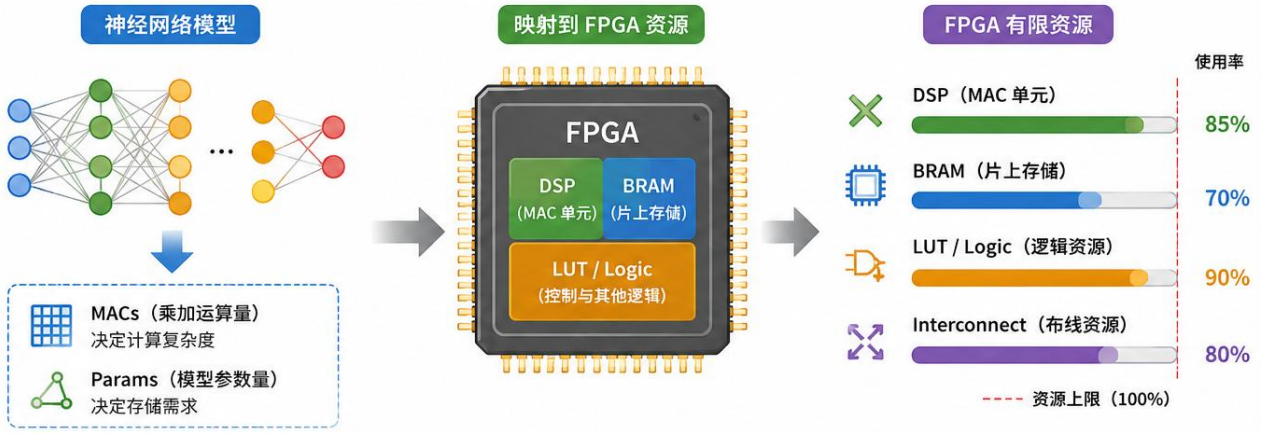
复杂声学环境挑战

真实场景中的低信噪比(SNR)、强混响(T60)以及移动声源，对单一特征的鲁棒性提出严苛要求。



边缘部署核心约束

边缘端部署不仅要求模型精度，还要求**模型在参数量、MAC、片上缓存和响应时延**上可落地，针对特定的网络结构设计特定的IP，以实现边缘需求的加速优化



相关研究现状——声源定位本课题的问题收束

中国传媒大学

研究现状一：定位任务持续扩展—SELD

技术核心： “定位任务已经从单一 DOA 走向更复杂的多任务或更灵活阵列建模”。

1.J. Wei et al., Real-Time Sound Event Localization and Detection: Deployment Challenges on Edge Devices, arXiv 2024.
2.Axel. Berg, J. Gulin, et al., "wav2pos: Sound Source Localization using Masked Autoencoders," Proc. ICASSP, 2024.
3.Y. Dong, Q. Wang, H. Hong, Y. Jiang and S. Cheng, "An Experimental Study on Joint Modeling for Sound Event Localization and Detection with Source Distance Estimation," ICASSP 2025

研究现状二：学习模型精度持续提升

技术核心：模型复杂度持续提升 从 CNN 到 CRNN、Transformer，复杂场景精度更强，但参数量和 MAC 也同步上升。

1.D. Diaz-Guerra, A. Miguel and J. R. Beltran, Direction of Arrival Estimation of Sound Sources Using Icosahedral CNNs, IEEE/ACM TASLP, 2023.
2.X.-C. Zhu et al., IFAN: An Icosahedral Feature Attention Network for Sound Source Localization, IEEE TIM, 2024.

研究现状三：硬件加速研究多为通用框架

技术核心：硬件加速研究多为通用框架，现有 FPGA/硬件加速更多针对通用卷积网络，较少直接面向声源方位估计与长时序相关网络

1.SAF-CNN: A Sparse Acceleration Framework of Convolutional Neural Network for Embedded FPGAs, 2023.
2.B. Ramhorst, V. Lončar and G. A. Constantinides, FPGA Resource-aware Structured Pruning for Real-Time Neural Networks, ICFPT 2023.

现有研究主要沿任务扩展、模型增强和通用硬件优化推进，而面向纯声源方位估计边缘部署的协同设计仍相对不足。

研究内容总览

总体目标：面向声源方位估计任务，在icoCNN球面卷积Baseline上提升复杂声学环境与运动场景下的定位稳定性，并实现边缘部署可行路径。

Problem

基线瓶颈诊断

特征信息单一
复杂场景不稳
部署代价高

Feature

PHAT + LMS 双特征

特征增强
互补空间证据

Network

DFA-IcoNet

双分支 +
注意力融合

Edge

DFA-IcoNet-Edge

r=2→r=1
C16→C8
轻量化基础主干

轻量化基础

Mamba

DFA-IcoNet-Edge-Mamba

pre_readout
Mamba
最终时序增强主线

Hardware

FPGA / HLS 映射

最终映射目标 =
ConvIco + Mamba
数据流 / 状态递推 /
资源预算

FPGA

从 icoCNN baseline 出发，逐步构建面向复杂场景与边缘部署的主线模型

状态逆推与时序增强，
带来更高硬件映射挑战

★ 当前工作主线

内容 1

面向边缘部署的
DFA-IcoNet-Edge
算法主线

内容 2

面向FPGA/HLS的
ConvIco 数据流与资
源闭合规划

统一实验验证口径

模拟四场景

声学环境鲁棒性
30dB / 5dB，T60 变化

LOCATA Task1 / Task3 / Task5

运动状态适应性
固定/移动麦克风，静态/动态声源

DCASE-2025 DOA

跨数据集的 DOA 对比
后续扩展验证

研究内容总览——实验验证环境构建

实验设置：模拟四场景与 LOCATA 真实数据

声源定位任务目标：从多通道麦克风信号估计声源方向，并验证模型在不同声学环境和运动状态下的稳定性。

- 运动状态包含 **3 类单源场景**：固定麦克风静态声源、固定麦克风移动声源、移动麦克风移动声源。
- 声学环境包含 **4 种典型难度组合**：30dB/T60=0.2s、30dB/T60=0.8s、5dB/T60=0.8s、5dB/T60=1.4s。
- 后续实验验证分为两条线：**模拟四场景用于声学环境鲁棒性测试，LOCATA Task1/3/5 用于运动状态适应性测试。**

本课题优势：依托 LOCATA 单源任务覆盖固定/移动麦克风、静态/动态声源等运动状态，同时用四种 SNR/T60 组合验证恶劣声学环境下的鲁棒性；**可补充目前 DCASE挑战赛音频片段作为跨数据集专项 DOA 对比。**

1 运动场景（三类单声源工况）



2 声学环境（4组SNR混响难度组合）

1	2	3	4
SNR = 30dB T60 = 0.2s	SNR = 30dB T60 = 0.8s	SNR = 5dB T60 = 0.8s	SNR = 5dB T60 = 1.4s

3 实验验证双分支路线



4 跨数据集验证



研究分析——baseline的优势、瓶颈、解决策略

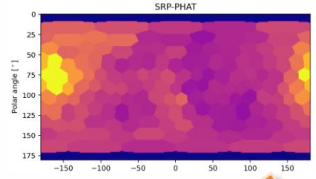
D. Diaz-Guerra, A. Miguel and J. R. Beltran, "Direction of Arrival Estimation of Sound Sources Using Icosahedral CNNs," in IEEE/ACM Transactions on Audio, Speech, and Language Processing, vol. 31, pp. 313-321, 2023

`icoCNN baseline` 优点：任务边界清晰，面向声源方位估计；球面卷积方式更匹配球面方向几何，避免等角投影极点过采样和普通平面卷积的几何错配。

icoCNN baseline 核心瓶颈

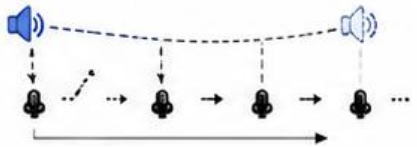
特征侧

单一PHAT特征在低 SNR.强混响和运动场景下易出现峰值扩散或伪峰,导致方位估计不稳定。



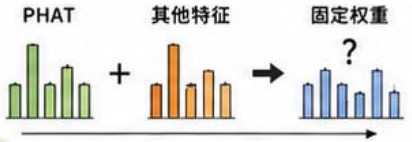
时序侧

声源或麦克风运动会带来跨帧时延变化，单帧 PHAT 图难以显式保留这种动态时延演化信息。



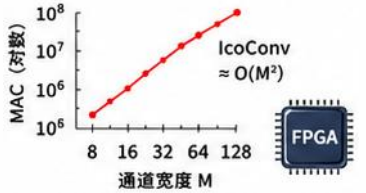
结构侧

仅处理单一空间响应,无法建模特征可靠性随SNR、混响和运动状态变化;简单拼接或相加也难以自适应保留可靠峰、抑制误峰。



端侧方面

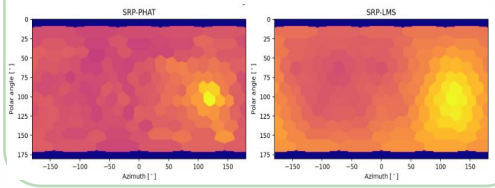
IcoConv计算量随通道宽度近似二次增长,FPGA/ HLS映射存在资源压力。



应对策略

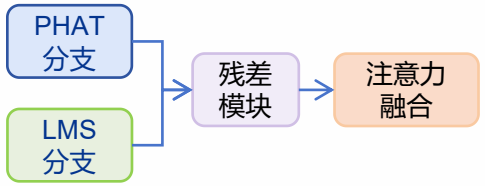
特征增强

引入LMS自适应时延特征,补充动态信息,与PHAT形成互补。



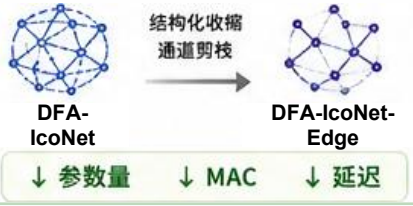
结构优化

设计双分支残差与注意力融合网络（DFA-IcoNet）增强特征表达与鲁棒性



结构压缩

提出DFA-IcoNet-Edge版本，通过结构化收缩降低参数量与计算量(MAC)。

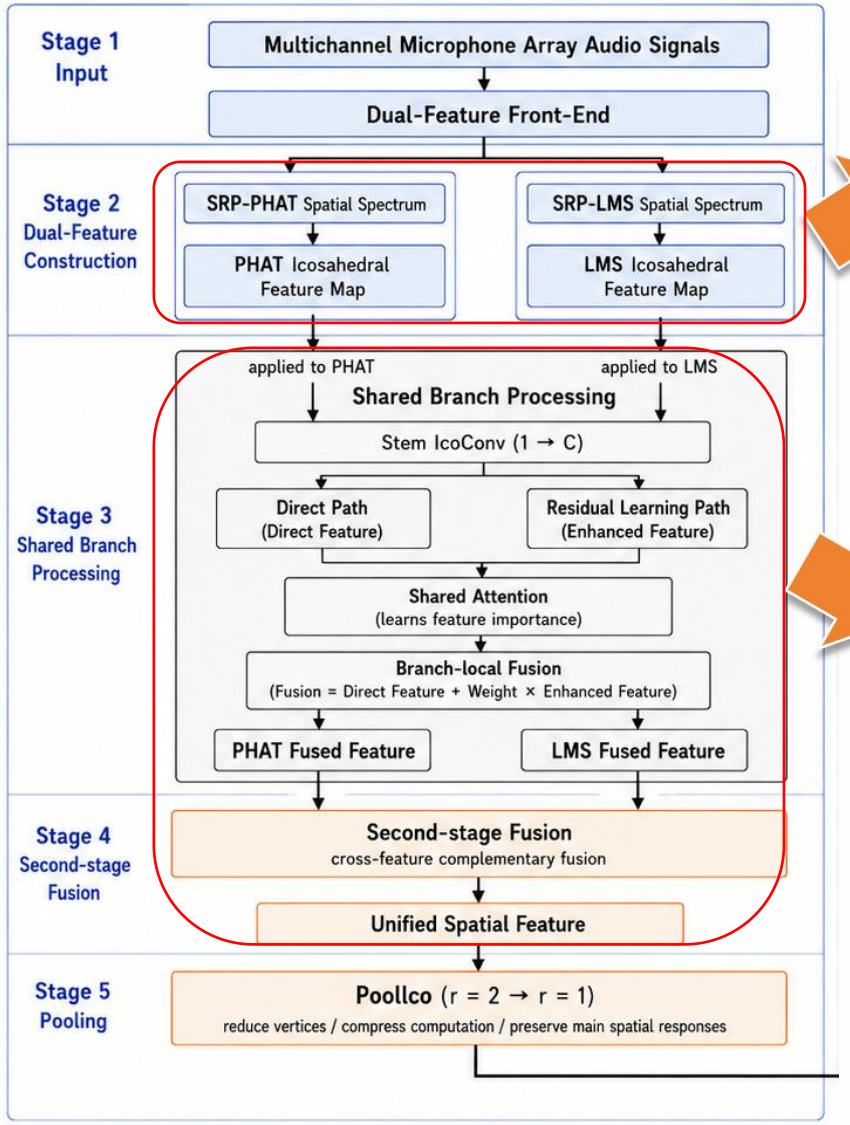


针对硬件映射的算法优化

聚焦网络后端ConvIco数据流与FPGA资源的高效闭合。



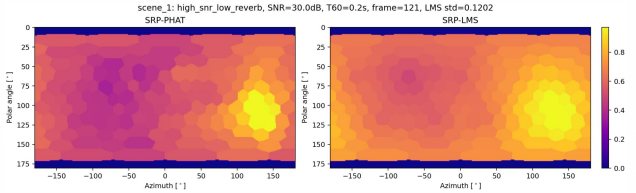
已完成工作1——算法主体链路搭建



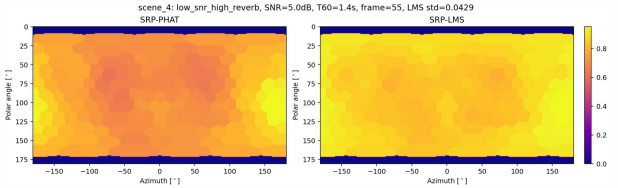
双特征前端

PHAT：在**高 SNR、低混响场景下峰值更清晰**，是稳健的空间定位基准线索。
LMS：来自自适应滤波的时延估计，在大混响或低 SNR 场景中**可保留与 DOA 相关的另一类证据**，但复杂混响下也可能误估。
因此 **LMS** 不是替代 PHAT，而是**补充 PHAT 在不同声学条件下失稳时的互补空间证据。**
双特征统一映射到二十面体网格，形成两通道输入

SNR=30dB T60=0.2s

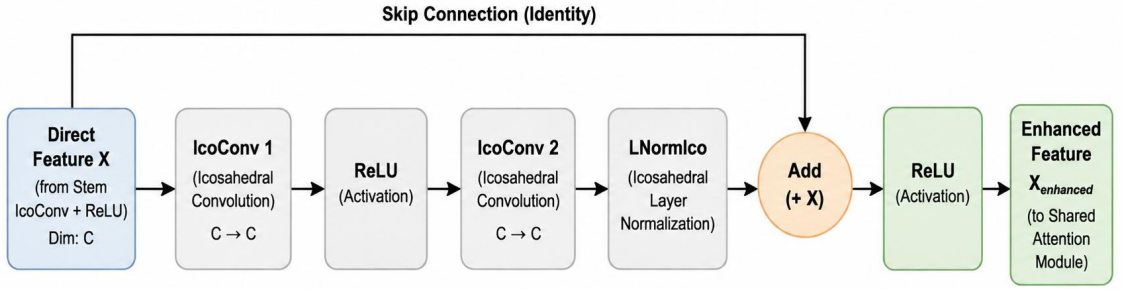


SNR=5.0dB T60=1.4s



双分支残差与注意力融合

每个分支保留直通特征，并通过 residual learning module 得到增强特征。
归一化增强特征：`LNormIco` 在残差相加前对增强分支做归一化，降低异常峰值或尺度波动对后续 attention 的影响
共享 attention weight module 根据输入声学环境学习特征权重，避免对两类响应做固定比例融合。



已完成工作1——验证结果

LOCATA挑战赛

Task1：固定麦克风阵列 + 静止声源
Task3：固定麦克风阵列 + 移动声源
Task5：移动麦克风阵列 + 移动声源

With Silences：计算 RMSAE 时包含静音帧
Without Silences：只看有效语音/声源活动段

评估指标-RMSAE

模型对每段 LOCATA 录音逐帧预测 DOA，然后和真实 DOA 做角度误差，最后对整段录音求均方根角度误差。

相关计算公式

Average = (Task1_mean * 13 + Task3_mean * 5 + Task5_mean * 5) / 23

With Silences

Model	Params	MAC	Task1 Mean	Delta	Task3 Mean	Delta	Task5 Mean	Delta	Std	Median	RMSAE Average	Delta
baseline	290017	647377920	6.26	0	10.7483	0	12.4059	0	4.1621	7.1128	**8.5718**	0
DFA-IcoNet	500129	2875207680	3.547	2.713	8.9943	1.7505	9.8423	-2.5636	3.4162	8.9943	**6.0997**	-2.4772

Without Silences

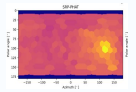
Model	Params	MAC	Task1 Mean	Delta	Task3 Mean	Delta	Task5 Mean	Delta	Std	Median	RMSAE Average	Delta
baseline	290017	647377920	6.0413	0	7.3898	0	10.0118	0	3.0529	7.174	**7.1976**	0
DFA-IcoNet	500129	2875207680	3.4374	-2.6039	7.0147	-0.3751	7.1467	-2.8651	2.1045	7.0147	**5.0214**	-2.1762

已完成工作2——面向部署的结构化压缩设计

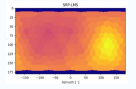
中国传媒大学

High-Res Fusion | Spatial Downsample | C16 → C8 | Dense DSP Tile

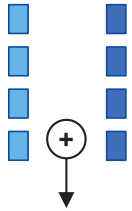
PHAT特征图



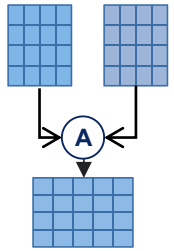
LMS特征图



Dual Branch Enhnancement
双分支残差增强



Attention Fusion at r=2
高分辨率双特征融合

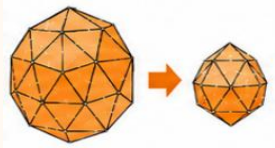


PoolIco Spatial Downsample

r = 2 → r = 1

降低后端空间分辨率

网格尺寸减小 / 缓存压力下降



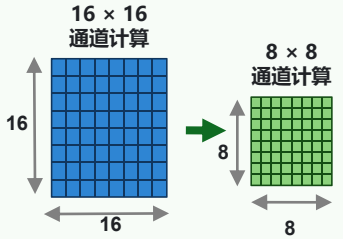
r = 2
高分辨率网格

r = 1
低分辨率网格

Dense Channel Slimming

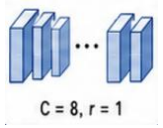
C = 16 → C = 8

规则通道压缩



DFA-IcoNet-Edge Backbone

4× FusionTemporalBlock
+ FinalFusionBlock



SAF-lite 结构化剪枝

- 2-of-8 稀疏模式
- 稀疏索引
- 非规则调度
- 零跳过控制
- 验证精度下降

选定路线

规则结构化压缩

- 稠密计算
- 规则数据流
- 无稀疏索引
- 控制路径简洁
- 适配 DSP Tile

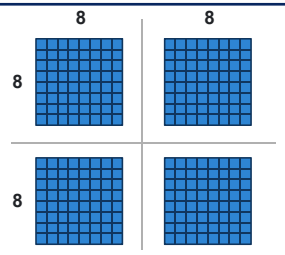
Spatial Downsample : r = 2 → r = 1

Channel Slimming : C = 16 → C = 8

DSP

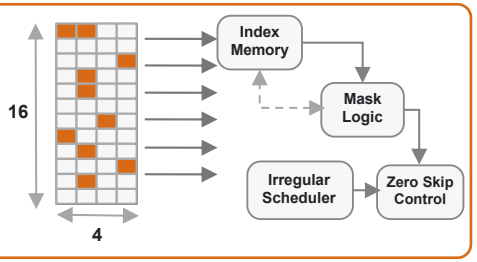
C16 Dense

16 × 16 channel block
= 4 × 8 × 8 DSP Tiles



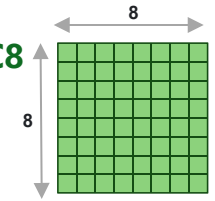
SAF-lite 2-of-8

Sparse 16 × 4 effective block
Index / Mask /
Irregular Control



DFA-IcoNet-Edge C8

8 × 8 dense block
= 1 complete DSP Tile



前端保持高分辨率双特征融合（r = 2）→ 后端降空间分辨率 （r = 2 → 1） → 全宽C16骨干压缩为规则稠密C8 → FPGA DSP Tile 映射

已完成工作2——结构化压缩实验验证

中国传媒大学

LOCATA挑战赛

Task1：固定麦克风阵列 + 静止声源
Task3：固定麦克风阵列 + 移动声源
Task5：移动麦克风阵列 + 移动声源

With Silences：计算 RMSAE 时包含静音帧
Without Silences：只看有效语音/声源活动段

评估指标-RMSAE

模型对每段 LOCATA 录音逐帧预测 DOA，然后和真实 DOA 做角度误差，最后对整段录音求均方根角度误差。

相关计算公式

Average = (Task1_mean * 13 + Task3_mean * 5 + Task5_mean * 5) / 23

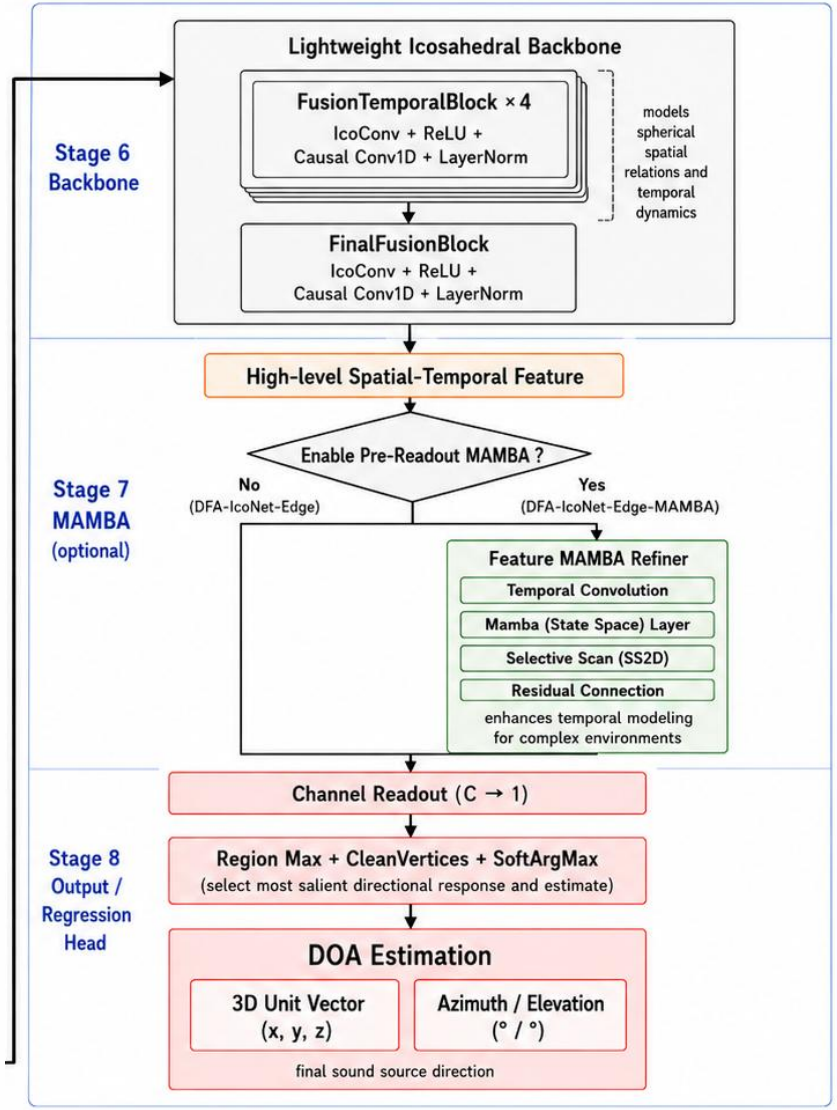
With Silences

Model	Params	MAC	Task1 Mean	Delta	Task3 Mean	Delta	Task5 Mean	Delta	Std	Median	RMSAE Average	Delta
baseline	290017	647377920	6.26	0	10.7483	0	12.4059	0	4.1621	7.1128	8.5718	0
DFA-IcoNet	500129	2875207680	3.547	2.713	8.9943	1.7505	9.8423	-2.5636	3.4162	8.9943	6.0997	-2.4772
DFA-IcoNet-Edge	31561	115211520	5.4455	-0.8144	10.1375	-0.6108	11.8516	-0.5543	4.1779	6.5339	7.8581	-0.7136

Without Silences

Model	Params	MAC	Task1 Mean	Delta	Task3 Mean	Delta	Task5 Mean	Delta	Std	Median	RMSAE Average	Delta
baseline	290017	647377920	6.0413	0	7.3898	0	10.0118	0	3.0529	7.174	7.1976	0
DFA-IcoNet	500129	2875207680	3.4374	-2.6039	7.0147	-0.3751	7.1467	-2.8651	2.1045	7.0147	5.0214	-2.1762
DFA-IcoNet-Edge	31561	115211520	5.4777	-0.5636	8.3455	0.9557	9.9599	-0.0519	3.3424	6.8928	7.0755	-0.1221

已完成工作—Mamba时序增强



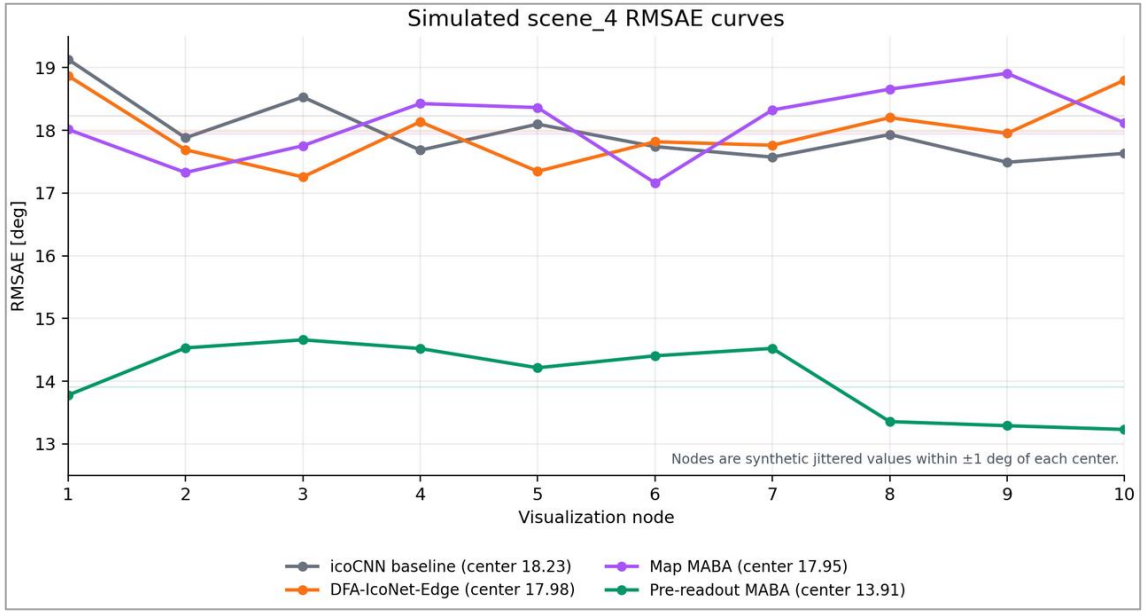


DFA-IcoNet-Edge仍保留 IcoConv 后的因果 1D 卷积，但**轻量化后在低 SNR、高混响和动态场景下可能出现跨帧响应不稳定。**

pre_readout Mamba 在 `final_block` 之后、`channel_readout` 之前进行 feature 级时序重整，用**状态扫描补充固定窗口 1D 卷积的局部建模。**

该位置仍保留多通道和多 region 信息，能在读出前抑制跨帧尖峰和伪峰。

当前确定扩展模型为 DFA-IcoNet-Edge-Mamba。



已完成工作—Maba时序增强结果

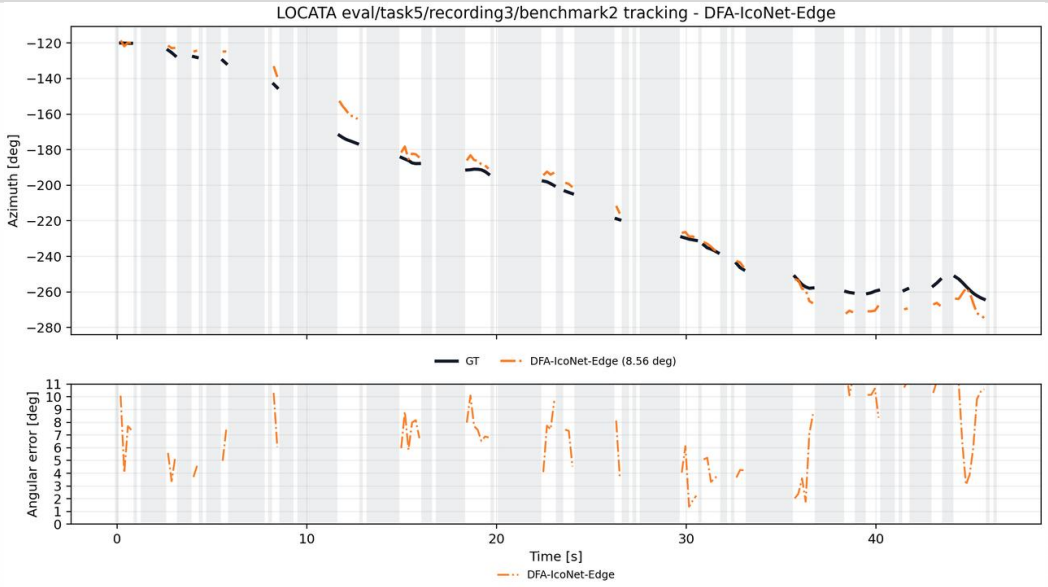
With Silences

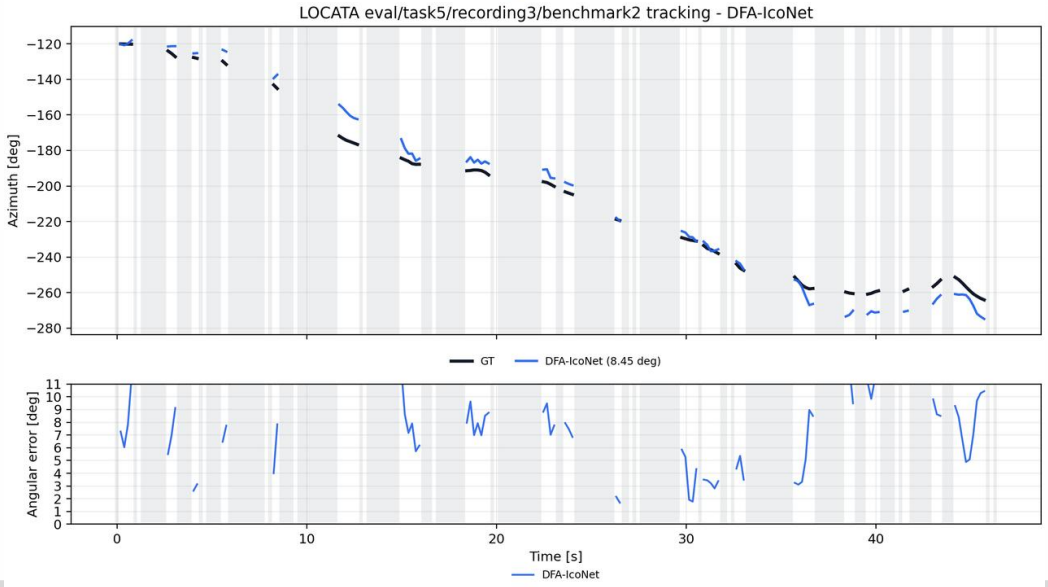
Model	Params	MAC	Task1 Mean	Delta	Task3 Mean	Delta	Task5 Mean	Delta	Std	Median	Average	Delta
baseline	**290017**	**647377920**	6.26	0	10.7483	0	12.4059	0	4.1621	7.1128	**8.5718**	0
DFA-IcoNet	500129	2875207680	3.547	2.713	8.9943	1.7505	9.8423	-2.5636	3.4162	8.9943	6.0997	-2.4772
DFA-IcoNet-Edge	31561	115211520	5.4455	-0.8144	10.1375	-0.6108	11.8516	-0.5543	4.1779	6.5339	7.8581	-0.7136
DFA-IcoNet-Edge-MABA	**32353**	**116213760**	5.5415	-0.7185	10.2378	-0.5105	11.2159	-1.19	3.7426	6.5392	**7.796**	-0.7758

Without Silences

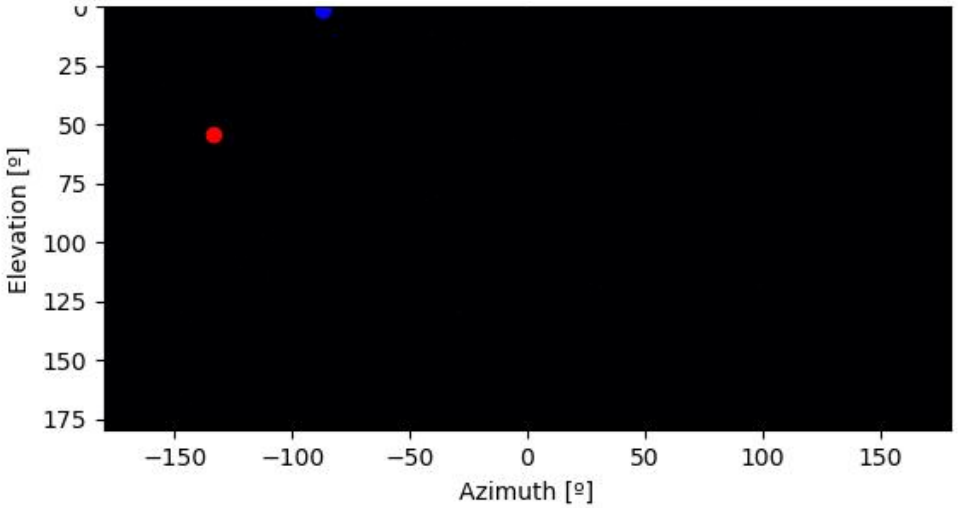
Model	Params	MAC	Task1 Mean	Delta	Task3 Mean	Delta	Task5 Mean	Delta	Std	Median	Average	Delta
baseline	**290017**	**647377920**	6.0413	0	7.3898	0	10.0118	0	3.0529	7.174	**7.1976**	0
DFA-IcoNet	500129	2875207680	3.4374	-2.6039	7.0147	-0.3751	7.1467	-2.8651	2.1045	7.0147	5.0214	-2.1762
DFA-IcoNet-Edge	31561	115211520	5.4777	-0.5636	8.3455	0.9557	9.9599	-0.0519	3.3424	6.8928	7.0755	-0.1221
DFA-IcoNet-Edge-MABA	**32353**	**116213760**	5.6588	-0.3825	8.5392	1.1494	8.5478	-1.464	2.5667	6.9061	**6.913**	-0.2846

已完成工作—Tracking 可视化

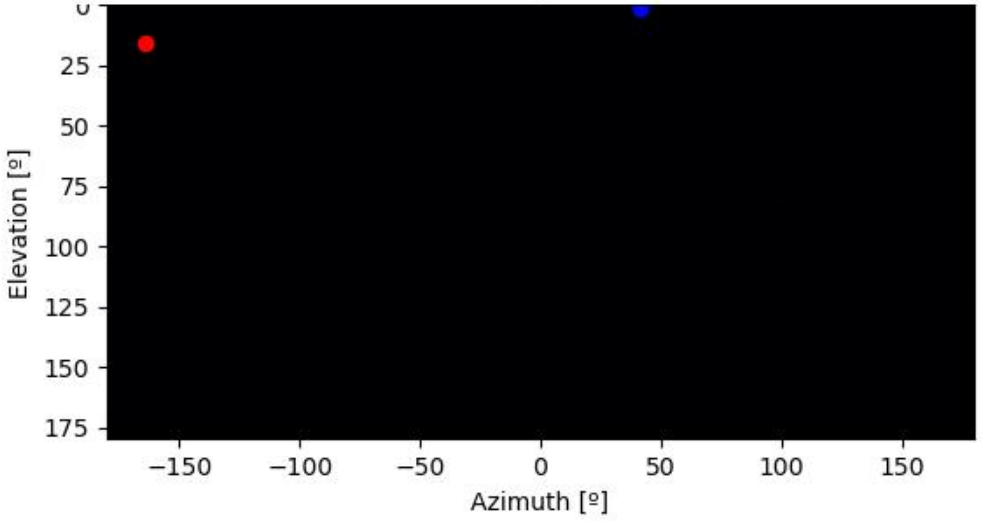




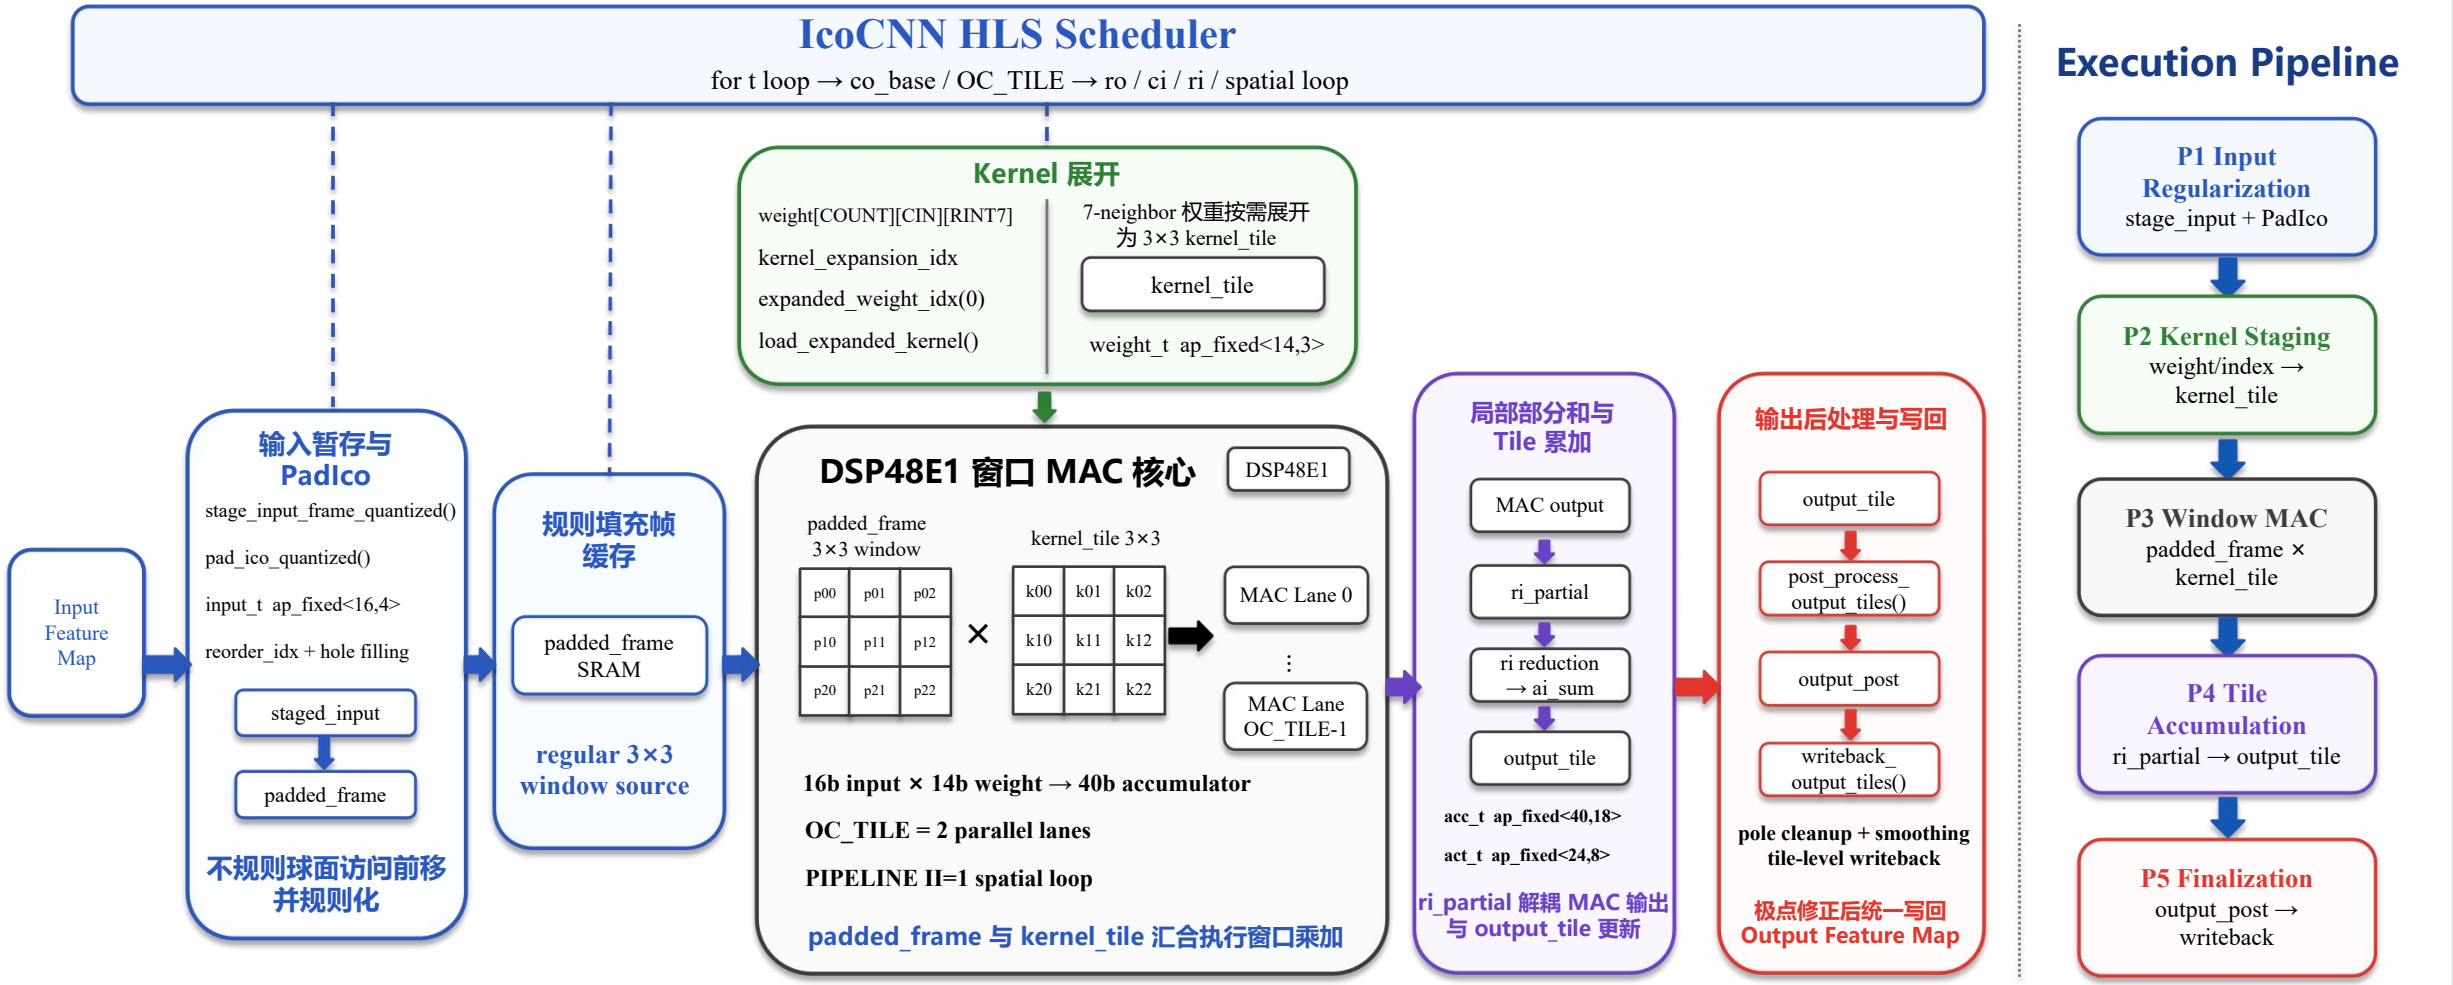
DFA-IcoNet-Edge-Mamba



DFA-IcoNet-Edge-Mamba



已完成工作——算法收束到硬件映射



复杂拓扑打平 | 构建局部窗口缓存，极大缓解直接访问全局特征引发的端口阻塞 | 紧凑权重寻址与循环展开 | 面向8x8收缩通道的稠密乘加吞吐 | 局部部分和累加与最终结果写回

通过将复杂的图节点邻接转化为规则的Local Buffer访问，将数据供给的延迟隐蔽于DSP高速计算流之下。

已完成工作——硬件映射资源

FPGA time = latency_cycles x clock_period　　GPU time = CUDA synchronized model forward wall-clock latency\
FPGA throughput = MAC_ip / FPGA time　　GPU throughput = MAC_model / GPU time

对象	口径	latency	FPS / 等效执行频率	理论吞吐
FPGA layer2-5	HLS C8/T6 synthetic, target 5ns	9.78 ms	约 102.2 次/s	54.9 GMAC/s / 109.7 GOPS
GPU DFA-IcoNet-Edge	software model_only	24.87 ms/sample	40.21 FPS	4.63 GMAC/s / 9.27 GOPS
GPU icoCNN baseline	software model_only	34.58 ms/sample	28.92 FPS	1.00 GMAC/s / 2.01 GOPS

IcoCNN

Timing

- Target Clock (ns): 5.00
- Estimated Clock (ns): 4.209

Latency

- Best: 261686621
- Avg: 261686621
- Worst: 261686621
- II Min: 261686622
- II Max: 261686622

Resource

Resource	Used	Available	Utilization
BRAM_18K	64	890	7.19%
DSP	72	840	8.57%
FF	43639	407600	10.71%
LUT	69382	203800	34.04%
URAM	0	0	N/A

Time 1D

Timing

- Target Clock (ns): 5.00
- Estimated Clock (ns): 3.867

Latency

- Best: 204914
- Avg: 204914
- Worst: 204914
- II Min: 204915
- II Max: 204915

Resource

Resource	Used	Available	Utilization
BRAM_18K	0	890	0.00%
DSP	160	840	19.05%
FF	39465	407600	9.68%
LUT	38494	203800	18.89%
URAM	0	0	N/A

当前已实现的硬件工作

1.Layer 0/1/2-5的独立HLS工程构建完成

2.核心Padico管道在Layer2-5中已达到阶段性Final II=1的最优调度

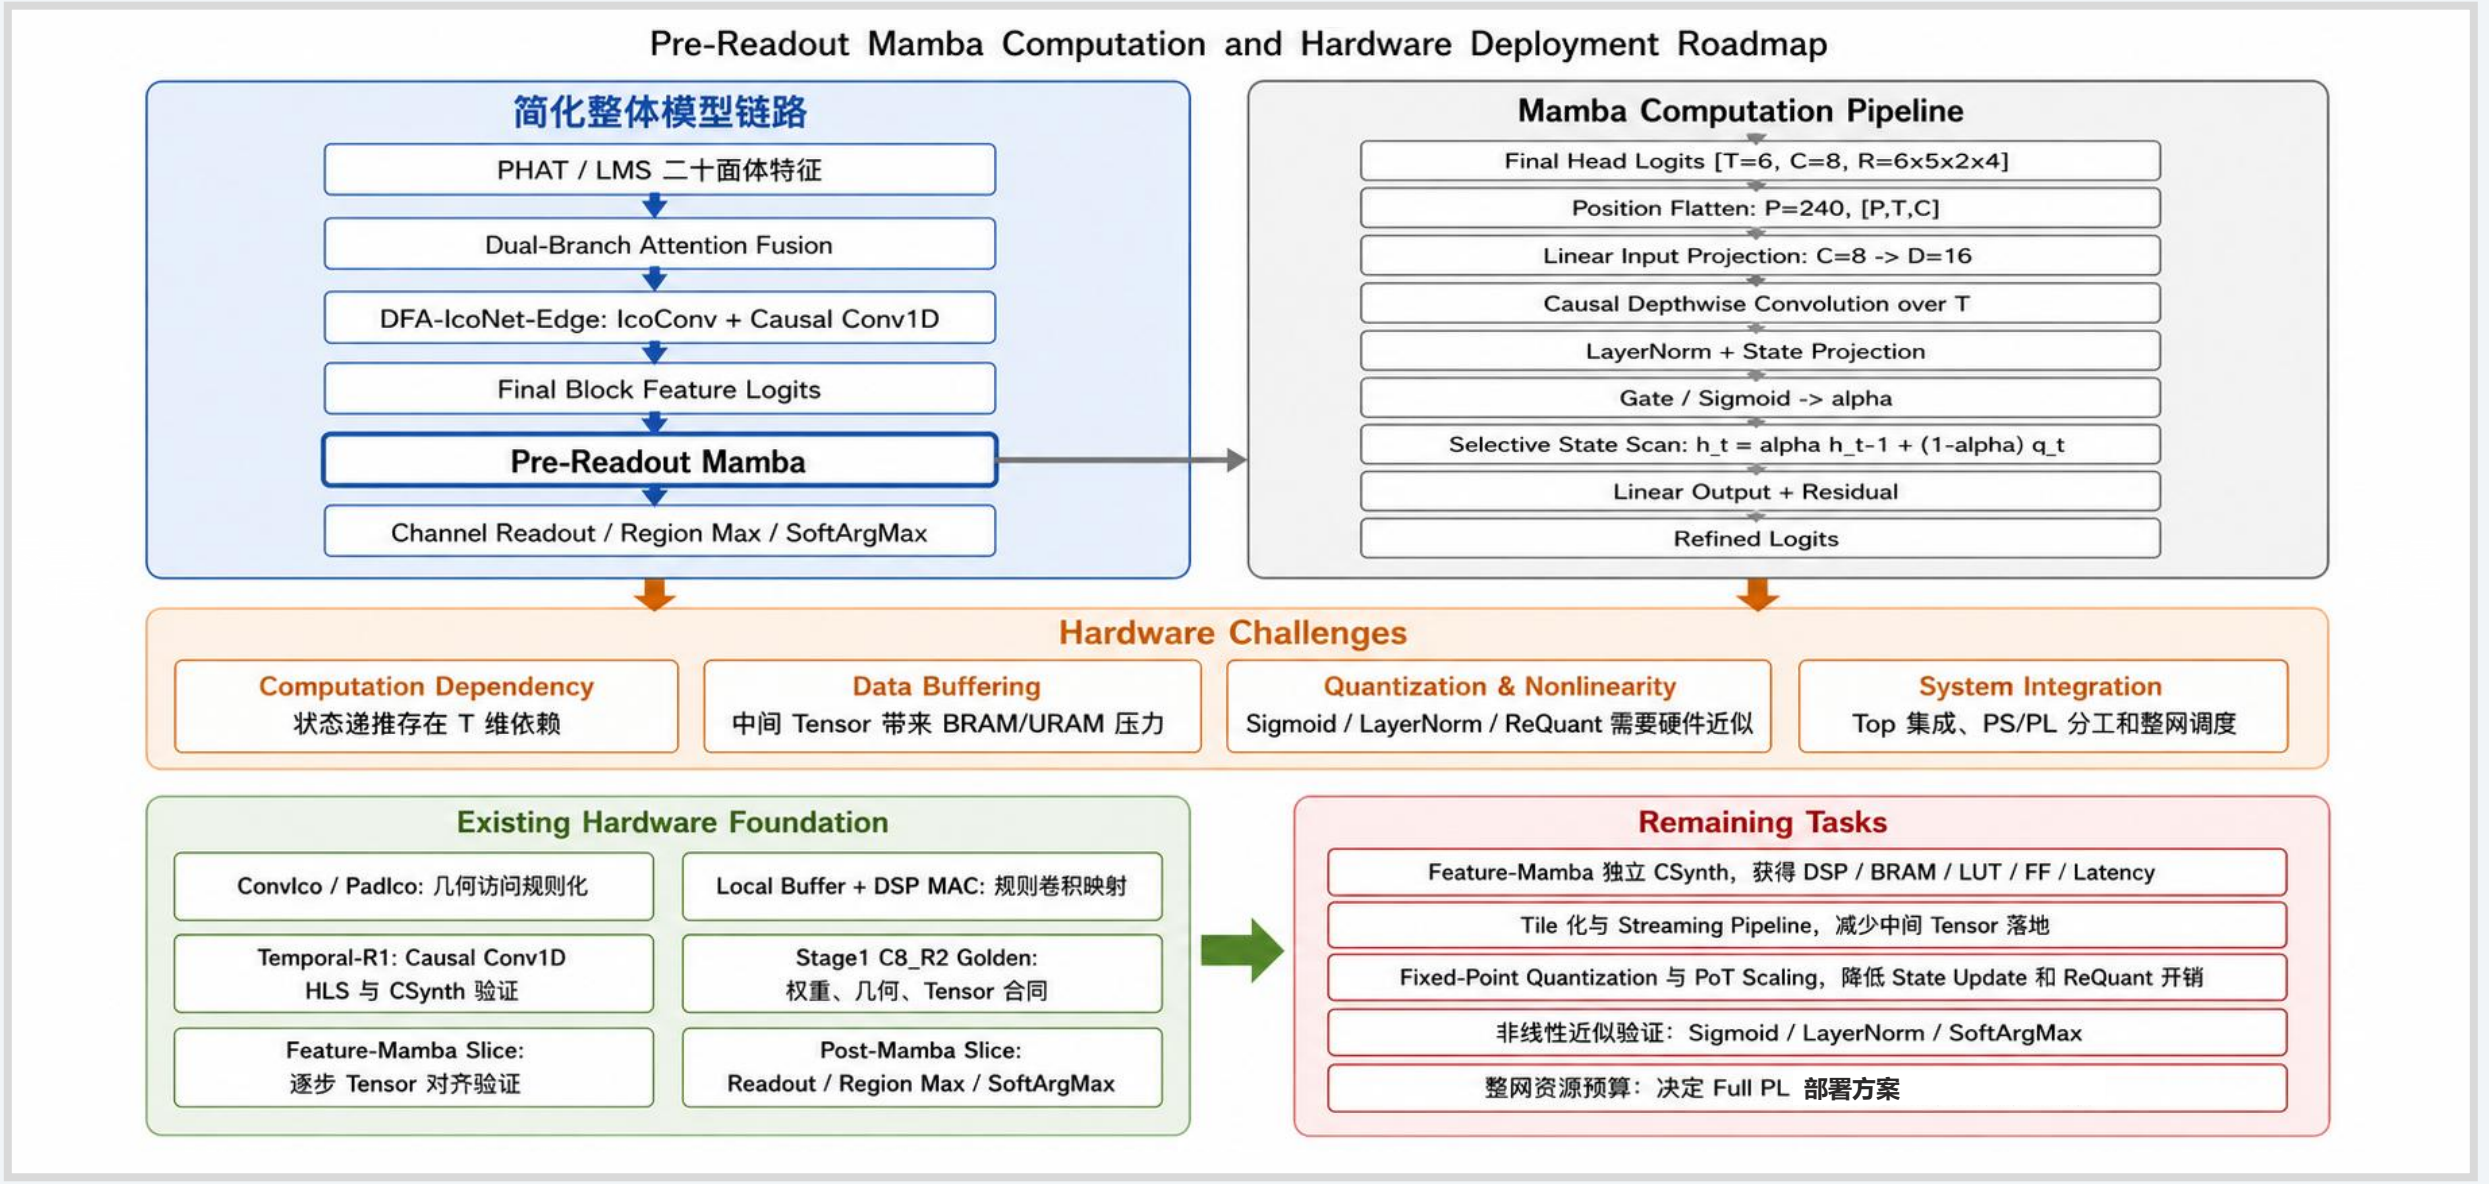
3.定点量化位宽与DSP-aware路径分析验证完毕

存在未解决的风险

浅层高分辨率网络（layer1）中，由于感受野扩张，存在LUT控制逻辑资源消耗大的问题

当前仅实现单层级以及局部的资源收敛，整网级别的全局资源统筹以及时序闭合扔是下阶段的核心工作

未来工作与挑战—Mamba的构建



工作时间安排

~~文献调研与基准复现~~
~~(2026.01-2026.02)~~
~~算法构建与架构优化~~
~~(2026.02-2026.03)~~
~~HLS实现与定点量化~~
~~(2026.03-2026.05)~~
~~硬件IP核开发与仿真~~
~~(2026.05-2026.07)~~
系统集成与实测调试
(2026.07 - 2026.10)
论文撰写与成果总结
(2026.10-2027.01)

